Détection de fraude par carte bancaire explicable

Challenge 2 : application web interactive, comparaison supervisé / non supervisé, seuil selon un coût en montants, explication de chaque alerte. Lyna Kamoun.

Problème métier

Les équipes d'analyse ne peuvent examiner qu'un nombre limité d'alertes par jour. Il leur faut un outil qui classe les transactions par niveau de risque, signale les plus suspectes dans un budget d'alertes, justifie le seuil par un coût et explique chaque alerte.

Données

Simulateur Sparkov (Kaggle, licence CC0) : 1 852 394 transactions de 999 cartes, de 2019 à 2020, dont 9 651 fraudes (0,52 %). Données synthétiques. Découpage chronologique 60 / 20 / 20 : validation du 7 avril au 25 août 2020, test du 25 août au 31 décembre 2020.

Variables : heure et jour en codage cyclique, nombre de transactions de la carte sur 1 h et 24 h, montant rapporté à la moyenne de 30 jours, délai depuis la transaction précédente, écart au montant habituel, distance porteur-marchand, catégorie. L'historique n'utilise que le passé strict de la carte.

Meilleur modèle

XGBoost, entraîné après sous-échantillonnage 1:20 des transactions normales (retenu sur la PR-AUC en validation, probabilités corrigées). Seuil de probabilité de 2,72 %, choisi sur la validation en minimisant le coût (montants des fraudes manquées + 5 par alerte analysée), puis confirmé sur le test.

Résultats sur la période de test

Méthode	PR-AUC	ROC-AUC	Rappel	Préc.	MCC	Coût
XGBoost	**0,900**	**0,998**	**95,1 %**	**40,8 %**	**0,621**	**28 908**
Rég. logist.	0,428	0,911	68,6 %	10,9 %	0,268	114 360
Isol. Forest	0,082	0,887	69,7 %	3,4 %	0,144	205 129
Sans modèle						733 912

Le coût passe de 733 912 sans modèle à 28 908, soit 96,1 % évités. Au budget de 20 alertes par jour (environ 1,5 fois le nombre moyen de fraudes par jour en validation), XGBoost retrouve 93,8 % des fraudes du test avec une précision de 49,1 %. La ROC-AUC est trompeuse ici : l'Isolation Forest atteint 0,887 pour une PR-AUC de 0,082.

Explications clés

- **Le montant domine** : contribution SHAP moyenne de 3,69 (log-odds), contre 1,26 pour l'heure et 1,16 pour la catégorie. Mélanger le montant fait tomber la PR-AUC de 0,917 à 0,012 ; mélanger la catégorie, à 0,19.
- **Une alerte type** (fraude détectée le 5 septembre 2020 à 23 h 41) : montant de 953,66 (+8,25), heure nocturne (+2,17), 3 transactions de la carte dans l'heure (+1,89). Ces codes motifs, de 3 à 5 variables, accompagnent chaque alerte dans l'application et dans l'API.
- Les explications SHAP additionnent exactement la prédiction : valeur moyenne + contributions = prédiction, vérifié dans les tests.

Recommandations

- **Déployer XGBoost au seuil de coût**, avec un budget d'alertes par jour et les alertes les plus probables examinées en premier. Pour XGBoost, le seuil optimal est le même pour un coût d'analyse de 5 ou de 10 ; le recalculer si ce coût change nettement.
- **Surveiller la dérive** : le taux de fraude baisse d'une période à l'autre (0,58 %, 0,51 %, 0,36 %). Réentraîner et réévaluer régulièrement.
- **Réserver le non supervisé** aux cas sans étiquettes ou à la surveillance : au même budget, ajouter les alertes de l'Isolation Forest récupère 9 fraudes manquées sur 84 et fait moins bien que donner ce budget à XGBoost (rappel de 0,944 contre 0,964).
- **Équité** : âge et genre ne sont pas utilisés. Ils améliorent la PR-AUC du test (0,900 à 0,936), mais l'âge identifie presque chaque porteur et ce sont des caractéristiques protégées. Surveiller l'écart observé : les femmes reçoivent 1,2 fois plus d'alertes et 1,6 fois plus de fausses alertes que les hommes.

Limites

- Données synthétiques : le modèle s'appuie surtout sur le montant et la catégorie, signature du simulateur (fraudes plafonnées à 1 376). Les performances ne se transposent pas telles quelles à des données réelles.
- Les mêmes cartes figurent dans les trois périodes : fuite de groupe à garder en tête.
- Un écart élevé au montant habituel réduit parfois le score, contraire à l'intuition ; cet effet et le mécanisme de l'écart entre genres ne sont pas expliqués. L'unité monétaire n'est pas précisée par la source ; le coût d'analyse de 5 est une hypothèse de travail.